

Bab 1: Pengantar Pembelajaran Mesin

</> Code ▾

Konsep Fundamental dan Workflow Pengembangan

Bab 1: Pengantar Pembelajaran Mesin (Introduction to ML)

Hasil Pembelajaran (Learning Outcomes)

Setelah mempelajari bab ini, Anda akan mampu:

1. **Memahami** konsep fundamental machine learning dan keterkaitan dengan AI/Data Science
2. **Menjelaskan** perbedaan antara tiga tipe pembelajaran: supervised, unsupervised, dan reinforcement learning
3. **Mengidentifikasi** masalah ML yang cocok untuk supervised vs unsupervised learning
4. **Mendesripsikan** workflow lengkap pengembangan ML project dari problem definition hingga deployment
5. **Menerapkan** best practices dalam setup environment Python untuk ML
6. **Mendiskusikan** pertimbangan etika dan tanggung jawab dalam membangun sistem ML

1.1 Pengantar: Mengapa Machine Learning Penting?

Machine Learning (Pembelajaran Mesin) telah merevolusi cara kita memecahkan masalah. Dari rekomendasi produk di Netflix hingga diagnosis medis yang lebih akurat, dari autonomous vehicles hingga deteksi fraud yang real-time—semuanya dimungkinkan oleh teknologi ML.

Definisi Machine Learning

Machine Learning adalah bidang studi yang memberikan kemampuan kepada komputer untuk **belajar dari data tanpa perlu diprogram secara eksplisit** untuk setiap skenario spesifik.

Dalam bab ini, kita akan membangun fondasi pemahaman tentang apa itu machine learning, mengapa penting, dan bagaimana cara kerjanya. Ini adalah landasan untuk semua yang akan kita pelajari di bab-bab berikutnya.

Pertanyaan Utama:

- Apa yang membedakan Machine Learning dari programming tradisional?
- Mengapa Machine Learning menjadi begitu penting?
- Bagaimana cara kerja sistem ML secara fundamental?

1.2 Apa Itu Machine Learning?

1.2.1 Definisi dan Konteks

Machine Learning adalah subset dari **Artificial Intelligence (AI)** yang fokus pada pengembangan sistem yang dapat **belajar dan meningkat dari pengalaman tanpa perlu reprogramming manual**.

Perbedaan kunci antara Traditional Programming dan Machine Learning:

Traditional Programming:
Input Data + Explicit Rules (if-then-else, logic) → Output

Machine Learning:
Input Data + Output Examples (Labels) → Rules Learned → Predictions

Dalam traditional programming, kita menulis aturan eksplisit. Dalam ML, kita memberikan contoh dan membiarkan algoritma menemukan aturannya sendiri.

1.2.2 Sejarah Singkat dan Evolusi

Machine Learning bukan konsep baru. Perjalanannya dimulai dari:

Tahun	Event	Signifikansi
1956	Konferensi Dartmouth	Kelahiran term “Artificial Intelligence”
1966	ELIZA chatbot	Simulasi psikiater pertama
1974-1980	AI Winter	Ekspektasi tinggi, hasil rendah

Tahun	Event	Signifikansi
1997	Deep Blue vs Kasparov	Computer mengalahkan world chess champion
2011	IBM Watson	Menang di Jeopardy!
2012	AlexNet	Revolusi deep learning dengan GPU
2016	AlphaGo vs Lee Sedol	AI mengalahkan Go master
2020-Present	Large Language Models	ChatGPT, GPT-4, era generative AI



Pembelajaran dari Sejarah

Setiap “AI Winter” mengajarkan kita tentang pentingnya ekspektasi realistis dan pemahaman mendalam tentang keterbatasan teknologi. Jangan percaya hype, fokus pada fundamentals.

1.2.3 Aplikasi ML di Dunia Real

Machine Learning digunakan di berbagai industri:


Domain	Aplikasi	Impact
Healthcare	Diagnosis penyakit, prediksi pasien risiko tinggi	Menyelamatkan nyawa, reduce costs
Finance	Deteksi fraud, prediksi market, credit scoring	Keamanan, efisiensi
E-commerce	Rekomendasi produk, demand forecasting	Meningkatkan sales, customer satisfaction
Transportation	Autonomous vehicles, route optimization	Safety, efficiency
Manufacturing	Predictive maintenance, quality control	Downtime reduction
Media/Entertainment	Content recommendations, generative content	User engagement
Security	Anomaly detection, threat prediction	Cybersecurity

1.3 Konsep Fundamental Machine Learning

1.3.1 Tiga Tipe Utama Learning

Machine Learning dapat dikategorikan berdasarkan cara sistem belajar:

► Code



Tiga Tipe Utama Machine Learning

Supervised Learning (Pembelajaran Terawasi)

Dalam supervised learning, **model belajar dari data berlabel** (labeled data), artinya setiap data input memiliki label output yang benar.

Karakteristik:

- Membutuhkan labeled training data
- Output target sudah diketahui

- Dapat mengukur akurasi dengan jelas

Dua kategori utama:

Problem					
Type	Tujuan	Output	Contoh	Algoritma	Metrik
Classification (Klasifikasi)	Memprediksi kategori/kelas	Diskrit (kategori terbatas)	Email spam/bukan spam, Cat/Dog/Bird, Approval/Reject	Logistic Regression, Decision Tree, SVM, Random Forest	Accuracy, Precision, Recall, F1-Score
Regression (Regresi)	Memprediksi nilai numerik kontinu	Nilai real numbers	Prediksi harga rumah, suhu besok, gaji berdasarkan pengalaman	Linear Regression, Decision Tree Regressor, SVR	MAE, RMSE, R ²

🔑 **Perbedaan Kritis: Classification vs Regression**

Classification: “Apakah email ini spam?” → Yes/No (Diskrit) **Regression:** “Berapa harga rumah ini?” → 2.5 miliar (Kontinyu)

Perbedaan ini penting karena menentukan algoritma dan metrik evaluasi yang digunakan!

Unsupervised Learning (Pembelajaran Tanpa Pengawasan)

Dalam unsupervised learning, **model belajar dari data tanpa label**, menemukan pola dan struktur tersembunyi.

Karakteristik:

- Tidak membutuhkan labeled data
- Output target tidak diketahui
- Fokus pada penemuan pola dan struktur

Dua kategori utama:

Problem Type	Tujuan	Output	Contoh	Algoritma	Metrik /
					Benefit
Clustering (Pengelompokan)	Mengelompokkan data serupa bersama	Cluster assignments	Segmentasi customer (high-value, medium, budget), document clustering	K-Means, Hierarchical Clustering, DBSCAN	Silhouette Score, Davies-Bouldin Index
Dimensionality Reduction	Mengurangi jumlah fitur sambil menjaga informasi	Data dengan dimensi lebih rendah	Visualisasi data tinggi-dimensi, feature extraction	PCA, t-SNE, UMAP	Visualisasi, computational efficiency, noise reduction

Reinforcement Learning (Pembelajaran Penguatan)

Dalam reinforcement learning, **agent belajar melalui interaksi dengan environment**, menerima reward atau penalty.

Karakteristik:

- Agent belajar dari rewards/penalties
- Sequential decision making
- Fokus pada policy optimization

Contoh aplikasi:

- AlphaGo bermain Go melawan opponents
- Autonomous vehicles learning navigation
- Game AI learning strategy optimal
- Robot manipulation tasks

1.3.2 Key Concepts: Features, Labels, dan Dataset

Sebelum memahami algoritma, penting mengerti struktur data dalam ML:

Features (Fitur/Input Variables - X):

- Input variables yang digunakan model untuk membuat prediksi
- Juga disebut “attributes” atau “independent variables”

- Contoh: untuk prediksi harga rumah → ukuran, lokasi, umur bangunan

Target/Label (Target Variable - Y):

- Output yang ingin diprediksi
- Juga disebut “dependent variable”
- Contoh: untuk prediksi harga rumah → harga rumah

Dataset:

- Kumpulan semua data point (samples)
- Setiap data point punya features (X) dan label (Y)

► Code

1.3.3 Train, Validation, dan Test Set


Salah satu konsep paling penting dalam ML adalah **tidak boleh mengevaluasi model pada data yang sama yang digunakan untuk training**.

Mengapa? Karena model bisa “menghafal” training data (overfitting) tanpa benar-benar generalize.

Pembagian Dataset:

- **Training Set (60-80%):** Data untuk melatih model
- **Validation Set (10-20%):** Data untuk tuning hyperparameter
- **Test Set (10-20%):** Data untuk evaluasi final (TIDAK boleh disentuh selama training!)

► Code



Pembagian Dataset untuk Training ML Model

⚠️ ⚠️ Data Leakage Warning!

Jangan pernah melakukan hal-hal ini:

- Preprocessing semua data bersama-sama sebelum split (akan bias)
- Menggunakan test set untuk tuning hyperparameter
- Mengevaluasi pada training data saja
- Scale/normalize data sebelum train-test split

Golden Rule: Test set harus truly unseen selama development phase!

1.3.4 Overfitting dan Underfitting

Saat melatih model, kita menghadapi trade-off penting antara kompleksitas model dan kemampuan generalisasi:

Underfitting:

- Model terlalu sederhana untuk data
- Training accuracy rendah, test accuracy juga rendah
- Model gagal menangkap pola penting
- **Sebab:** Model complexity terlalu rendah, tidak cukup data

Overfitting:


- Model terlalu kompleks, “menghafal” training data detail
- Training accuracy tinggi, test accuracy rendah

- Model gagal generalisasi ke data baru
- **Sebab:** Model complexity terlalu tinggi, overtraining

Good Fit:

- Balanced complexity
- Training dan test accuracy keduanya tinggi
- Model generalize dengan baik ke data baru
- **Tujuan:** Yang kita inginkan!

► Code



Underfitting vs Overfitting vs Good Fit

Cara mengatasi:

Problem	Solusi
Underfitting	Tambah data, tambah feature, gunakan model lebih kompleks
Overfitting	Gunakan regularization, kurangi feature, gunakan model lebih sederhana

1.3.5 Bias-Variance Tradeoff

Dua konsep penting yang mempengaruhi model generalization:

Bias = Seberapa jauh prediksi model secara konsisten dari nilai sebenarnya (underfitting) **Variance** = Seberapa banyak prediksi berubah jika kita melatih dengan data yang berbeda (overfitting)

High Bias + Low Variance:	Underfitting (terlalu sederhana)
Low Bias + High Variance:	Overfitting (terlalu kompleks)
Low Bias + Low Variance:	Ideal! (apa yang kita inginkan)

Strategi:


- Tambah data training → reduce variance
- Tambah model complexity → reduce bias
- Gunakan cross-validation → better estimate
- Gunakan regularization → reduce variance


1.4 Workflow Pengembangan Machine Learning

Membangun sistem ML yang baik adalah proses sistematis, bukan random.

Berikut adalah workflow lengkap:

► Code





Complete Machine Learning Development Workflow

Mari kita bahas setiap langkah:

Step 1: Problem Definition (🎯)

Langkah pertama dan **paling penting** adalah memahami masalah dengan jelas.

Pertanyaan yang harus dijawab:

- Apa yang ingin kita prediksi/optimize?
- Apa problem type? (Classification, Regression, Clustering, dsb)
- Apa business metrics/success criteria?
- Apa constraints? (Latency, computational resources, ethical considerations)
- Bagaimana hasil akan digunakan dalam practice?

💡 Real-world Example: Netflix Churn Prediction

Problem: Netflix ingin mengurangi customer churn (pelanggan yang cancel)

Clear Problem Definition:

- **Task:** Memprediksi customer mana yang berisiko cancel dalam 3 bulan
- **Problem Type:** Binary Classification
- **Success Metric:** Recall $\geq$ 85%
- **Use Case:** Proactive retention campaign
- **Business Value:** Reduce churn → increase lifetime value

Step 2: Data Collection (📊)

Kualitas data menentukan kualitas model. “Garbage in, garbage out.”

Tujuan:

- Kumpulkan data relevan untuk problem
- Pastikan sufficient volume
- Dokumentasikan sumber data

Pertimbangan:

- Apakah data memiliki signal yang cukup?
- Apakah available features relevant dengan target?
- Bagaimana distribusi data? (Balanced/imbalanced?)
- Apakah ada data quality issues?

Step 3: Data Preprocessing (🖌)

Data real-world selalu “kotor”. Preprocessing adalah ~70% pekerjaan data science!

Aktivitas utama:

- Handle missing values
- Remove/treat outliers
- Encode categorical variables
- Scale/normalize numerical features
- Handle class imbalance (jika applicable)

► Klik untuk melihat contoh data preprocessing

Step 4: Exploratory Data Analysis (🔍)

Sebelum modeling, kita harus understand data secara mendalam.

Aktivitas:

- Univariate analysis (distribusi setiap feature)
- Bivariate analysis (relationship antara features)
- Multivariate analysis (pattern dalam keseluruhan)
- Visualisasi dan statistik deskriptif

Output: Insights tentang data, feature importance, potential issues

Step 5: Feature Engineering (⚙)

Transform raw data menjadi features yang lebih predictive.

Teknik:

- Create polynomial features
- Interaction terms
- Domain-specific features
- Feature selection untuk menghilangkan features tidak penting

Contoh:

```
Raw features: BirthDate, CurrentDate  
→ Engineered feature: Age = CurrentDate - BirthDate  
→ Better for ML model!
```

Step 6: Model Selection (🛠️)

Pilih algorithm yang sesuai dengan problem type dan karakteristik data.

Pertimbangan:

- Problem type (Classification/Regression/Clustering?)
- Data volume (berapa samples?)
- Feature dimensionality (berapa features?)
- Interpretability requirements
- Computational resources available

Best Practice: Start simple, kemudian add complexity jika diperlukan.

Step 7: Model Training (📈)

Latih model pada training set.

► Klik untuk melihat contoh training model

Step 8: Model Evaluation (✅)

Evaluasi dengan metrics yang sesuai untuk problem type.

► Klik untuk melihat model evaluation

Step 9: Iterate & Improve (🔄)

Jika performance tidak memuaskan, kembali ke langkah sebelumnya:

- Tune hyperparameters
- Try different algorithms
- Get more/better data
- Engineer better features
- Adjust class weights (jika imbalanced)

Step 10: Deployment (📦)

Deploy model ke production environment.

Considerations:

- API endpoint untuk predictions
- Batch processing jika diperlukan
- Model versioning dan tracking
- A/B testing sebelum full rollout

Step 11: Monitoring & Maintenance (📡 🔧)

Monitor model performance di production.

Metrik untuk dipantau:

- Prediction latency
- Model accuracy (jika ground truth tersedia)
- Data drift (apakah input distribution berubah?)
- Concept drift (apakah relationship berubah?)

1.5 Tools dan Environment Setup

1.5.1 Python Ecosystem untuk ML

Core Libraries:

1. **NumPy** - Numerical computing
 - Arrays, matrices, mathematical operations
 - Foundation untuk kebanyakan libraries lain
2. **Pandas** - Data manipulation
 - DataFrames untuk data wrangling

- Data cleaning, exploratory analysis
- SQL-like operations pada data

3. **Scikit-learn** - Classical ML algorithms

- Supervised learning (classification, regression)
- Unsupervised learning (clustering, dimensionality reduction)
- Model selection dan evaluation tools

4. **Matplotlib & Seaborn** - Data visualization

- Create plots, charts, visualizations
- Statistical graphics

5. **Jupyter/IPython** - Interactive development

- Notebooks untuk exploration dan teaching
- Code, visualizations, narrative dalam satu document

For Deep Learning (akan di-cover di chapter 5+):

- TensorFlow/Keras
- PyTorch
- JAX

1.5.2 Environment Setup

Installation Guide

Complete installation guide tersedia di Appendix A: Installation Guide.

Quick Setup:

```
# Create virtual environment
python -m venv ml-env
source ml-env/bin/activate

# Install essential packages
pip install numpy pandas scikit-learn matplotlib seaborn jupyter
```

Lihat appendix untuk:

- Detailed instructions untuk berbagai OS
- Troubleshooting tips
- Virtual environment best practices

1.6 Ethical Considerations dalam ML

Machine Learning bukan neutral technology. Keputusan dalam setiap step development bisa punya ethical implications yang besar.

1.6.1 Bias dalam ML

Sumber bias:

1. **Data bias** - Training data tidak representative dari real-world
2. **Algorithm bias** - Algoritma inherently biased
3. **Human bias** - Biases dalam problem definition, feature selection

Contoh nyata:

- Hiring algorithm yang biased terhadap perempuan
- Healthcare algorithm yang underperform untuk minority groups
- Loan approval system yang discriminate based on protected attributes

1.6.2 Fairness, Accountability, dan Transparency

Principles untuk ethical ML:

- **Fairness:** Model treat different groups fairly, tidak ada discrimination
- **Accountability:** Clear responsibility untuk model decisions
- **Transparency:** Model decisions harus explainable/interpretable

1.6.3 Privacy Concerns

Issues:

- Model bisa memorize sensitive training data
- Adversarial attacks bisa extract private information
- GDPR “right to be forgotten” vs model predictions

1.6.4 Best Practices untuk Ethical ML

Ethical ML Practices

1. **Understand your data:** Dari mana data? Apa limitations-nya?
2. **Check for bias:** Apakah model perform equally well untuk semua groups?
3. **Be transparent:** Explain model decisions ke stakeholders

4. **Consider impact:** Bagaimana model decisions mempengaruhi users?
5. **Have governance:** Processes untuk monitoring dan addressing issues
6. **Document decisions:** Keep track of why certain choices were made

1.7 Case Study: Churn Prediction untuk Telekomunikasi

Mari aplikasikan konsep-konsep ini pada case study nyata.

Problem Definition

- **Objective:** Prediksi pelanggan yang akan churn (cancel) dalam 3 bulan
- **Problem Type:** Binary Classification
- **Success Metric:** Recall $\geq$ 85% (identify 85% of actual churners)

Data Collection & Exploration

- Dataset: 7043 customers
- Features: Demographics, usage patterns, billing info
- Target: Churn (Yes/No)
- Class balance: ~26% churn (imbalanced)

Preprocessing

- Handle missing values
- Encode categorical variables
- Scale numerical features
- Handle class imbalance dengan SMOTE

Modeling

Tried several algorithms:

- Logistic Regression: 80% recall
- **Random Forest: 87% recall** ← Selected
- Gradient Boosting: 85% recall

Results

- Test Recall: 87.3%  (exceeds 85% goal)
- Precision: 54.2%
- Business impact: Saves millions dalam revenue melalui proactive retention



Hands-on Exercise 1

Objektif: Practice fundamental concepts dengan kode

Instruksi:

1. Buka Jupyter notebook
2. Import libraries yang diperlukan (pandas, numpy, sklearn)
3. Load Iris dataset
4. Explore data (shape, summary statistics)
5. Split into train (80%) dan test (20%)
6. Scale features dengan StandardScaler
7. Train LogisticRegression classifier
8. Evaluate dengan accuracy, precision, recall

Bonus: Visualize confusion matrix



Review Questions

Conceptual Questions

1. Jelaskan dengan jelas perbedaan antara **supervised learning** dan **unsupervised learning**. Berikan 2 contoh untuk masing-masing dan jelaskan mengapa klasifikasi tersebut tepat.
2. Dalam konteks **classification vs regression**, jelaskan perbedaan kedua problem types. Kapan kita gunakan classification? Kapan regression? Berikan contoh nyata untuk masing-masing.
3. Jelaskan fenomena **overfitting dan underfitting**. Bagaimana cara mendeteksi keduanya? Apa strategi untuk mengatasinya?
4. Mengapa penting untuk memiliki **separate test set** yang tidak disentuh selama training phase? Apa yang terjadi jika kita evaluate model pada training data saja?

5. Jelaskan **bias-variance tradeoff**. Bagaimana tradeoff ini mempengaruhi generalization ability model?

Practical Questions

6. Diberikan problem: “Prediksi apakah email masuk adalah spam atau bukan.” Ini classification atau regression? Supervised atau unsupervised? Jelaskan alasan.
7. Jelaskan langkah-langkah apa yang akan Anda lakukan untuk membangun ML model untuk problem di nomor 6.
8. Jika training accuracy = 95% tetapi test accuracy = 60%, apa yang terjadi? Apa solusi yang Anda rekomendasikan dan mengapa?
9. Anda punya dataset dengan 1000 samples. Berapa yang Anda alokasikan untuk training, validation, dan test? Jelaskan alasan di balik pilihan Anda.
10. Dataset Anda sangat imbalanced: 95% negative class, 5% positive class. Bagaimana Anda akan handle imbalance ini? Apa metrik evaluasi yang sesuai?



Key Takeaways:

- ✓ Machine Learning adalah teknologi powerful untuk memecahkan complex problems dari data
- ✓ Ada tiga tipe utama: **supervised** (labeled), **unsupervised** (no labels), **reinforcement** (reward)
- ✓ ML workflow adalah systematic process dari problem definition hingga monitoring
- ✓ **Ethical considerations** harus menjadi bagian integral dari development, bukan afterthought
- ✓ Tools Python (pandas, sklearn, matplotlib) membuat ML accessible dan powerful
- ✓ **Bias-variance tradeoff** adalah fundamental concept yang mengatur model generalization



References dan Resources

Bacaan Lebih Lanjut

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Müller, A. C., & Guido, S. (2016). *Introduction to Machine Learning with Python*. O'Reilly.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*.

Online Resources

- Scikit-learn Documentation: <https://scikit-learn.org/>
- Kaggle Datasets: <https://www.kaggle.com/datasets>
- Papers with Code: <https://paperswithcode.com/>
- Google ML Crash Course: <https://developers.google.com/machine-learning/crash-course>

Tools & Platforms

- Jupyter Notebook: <https://jupyter.org/>
- Anaconda Distribution: <https://www.anaconda.com/>
- Kaggle Notebooks: <https://www.kaggle.com/code>



Kesimpulan

Anda sekarang memiliki pemahaman fundamental tentang **Machine Learning**:

- Apa itu ML dan mengapa penting
- Tiga tipe learning dan kapan menggunakannya
- Workflow lengkap dari problem definition hingga deployment
- Tools dan environment untuk ML development
- Ethical considerations dalam ML

Di **Bab 2 (Data Preprocessing & EDA)**, kita akan deep dive ke dalam aspek kritis: bagaimana mempersiapkan data berkualitas tinggi untuk modeling. Data quality adalah fondasi dari model quality! 🚀
