



Bab 2: Data Preprocessing dan Exploratory Data Analysis

[</> Code ▾](#)

Mempersiapkan Data Berkualitas Tinggi untuk Machine Learning

Bab 2: Data Preprocessing dan Exploratory Data Analysis (EDA)

Hasil Pembelajaran (Learning Outcomes)

Setelah mempelajari bab ini, Anda akan mampu:

1. **Melakukan** exploratory data analysis (EDA) komprehensif untuk memahami struktur dan karakteristik data
2. **Mengidentifikasi** dan **menangani** missing values dengan strategi yang tepat
3. **Mendeteksi** dan **mengatasi** outliers menggunakan berbagai teknik
4. **Mengencode** variabel kategorikal dengan metode yang sesuai untuk ML
5. **Menerapkan** feature scaling dan normalization secara efektif
6. **Mengrekayasa** fitur-fitur baru yang meningkatkan predictive power model
7. **Mencegah** data leakage dan memastikan data quality untuk production models

2.1 Pengantar: Pentingnya Data Quality



Garbage In Garbage Out (GIGO) prinsip

Data adalah jantung dari setiap ML project. Algoritma terbaik sekalipun tidak bisa menghasilkan model berkualitas jika dilatih dengan data berkualitas rendah. Dalam praktik nyata, **70-80% waktu data scientist dihabiskan untuk data preprocessing dan EDA**, bukan untuk modeling.

Dalam bab ini, kita akan mempelajari:

- Bagaimana **memahami data secara mendalam** melalui EDA
- Bagaimana **membersihkan dan mempersiapkan data** untuk modeling
- Bagaimana **menangani masalah umum** seperti missing values dan outliers
- Bagaimana **mengrekayasa fitur** yang lebih powerful
- Bagaimana **mencegah data leakage** dan memastikan reproducibility

Pertanyaan Utama:

- Bagaimana cara memahami dataset baru secara sistematis?
- Apa masalah data quality yang umum dan bagaimana mengatasinya?
- Bagaimana cara mempersiapkan data sehingga siap untuk algoritma ML?

2.2 Exploratory Data Analysis (EDA)

! Important

EDA adalah proses investigasi sistematis terhadap dataset untuk memahami karakteristik, pola, dan anomalinya. EDA bukan tentang membuat model, tetapi tentang **memahami data**, mencari *insight* yang tersembunyi dalam data.

2.2.1 Tujuan dan Aktivitas EDA


Tujuan EDA:

- Understand data structure dan content
- Identify missing values, outliers, anomalies
- Discover patterns dan relationships
- Generate hypotheses untuk selanjutnya

- Inform preprocessing dan feature engineering decisions

Aktivitas EDA:

► Code



Exploratory Data Analysis Process Flow

2.2.2 Step 1: Load & Inspect Data

Langkah pertama adalah memuat data dan mendapatkan gambaran awal.

► [Code](#)

2.2.3 Step 2: Univariate Analysis

Analisis setiap variabel secara individual untuk memahami distribusinya.

Untuk Variabel Numerik:

- Central tendency: Mean, median, mode
- Spread: Std dev, variance, range
- Shape: Skewness, kurtosis
- Visualisasi: Histogram, KDE plot, box plot

► [Klik untuk melihat univariate analysis](#)

Untuk Variabel Kategorikal:

- Frequency distribution
- Unique values count
- Mode
- Visualisasi: Bar plot, pie chart

► [Categorical variable analysis](#)

2.2.4 Step 3: Bivariate Analysis

Analisis relationship antara dua variabel.

► [Bivariate analysis examples](#)

2.2.5 Step 4: Multivariate Analysis & Correlation Heatmap

► [Correlation heatmap](#)

2.3 Data Cleaning & Preprocessing

Data real-world selalu memiliki masalah. Mari kita belajar cara mengatasinya.

2.3.1 Handling Missing Values

Missing values dapat terjadi karena:

- Data entry errors
- Equipment failure
- Confidentiality reasons
- Data loss

⚠ Missing Value Strategies


Jangan pernah menghapus semua rows dengan missing values tanpa pertimbangan!

Pilih strategi berdasarkan:

- Seberapa banyak missing values (threshold)?
- Apakah missing values MCAR, MAR, atau MNAR?
- Pentingnya variabel tersebut
- Dampak pada model performance

Strategi Handling Missing Values:

► Code



Missing Values Handling Strategies

Metode Imputation:

- Missing value handling examples

2.3.2 Handling Outliers

Outliers adalah nilai yang sangat berbeda dari mayoritas data. Mereka bisa:

- **Valid:** Natural variation (e.g., billionaire dalam dataset income)
- **Invalid:** Data entry error, sensor malfunction

Deteksi Outliers:

Method 1: IQR (Interquartile Range)

```
Q1 = 25th percentile
Q3 = 75th percentile
IQR = Q3 - Q1

Lower Bound = Q1 - 1.5 * IQR
Upper Bound = Q3 + 1.5 * IQR

Outliers = values outside [Lower Bound, Upper Bound]
```

Method 2: Z-Score

```
Z = (value - mean) / std_dev

|Z| > 3 ≈ 99.7% of data (likely outlier)
```


► Outlier detection methods

2.3.3 Encoding Categorical Variables

Algoritma ML membutuhkan input numerik. Variabel kategorikal perlu diencode.

Strategi Encoding:

► Code



Categorical Variable Encoding Strategies

► Categorical encoding examples

⚠ One-Hot Encoding Caution

Dummy Variable Trap: Jika memiliki k kategori, jangan buat k dummy variables!

Gunakan k-1 dummy variables (drop first category) untuk menghindari perfect multicollinearity.

```
pd.get_dummies(df['col'], drop_first=True)
```



2.3.4 Feature Scaling & Normalization

Beberapa algoritma sensitif terhadap skala feature (e.g., distance-based, gradient-based). Scaling menormalisasi features ke range yang sama.

Metode Scaling:

► Feature scaling methods

Kapan menggunakan scaling?

Algoritma	Membutuhkan Scaling?
Linear Regression, Logistic Regression	✔ Yes
Neural Networks	✔ Yes
SVM, KNN	✔ Yes
Decision Trees, Random Forest	✘ No
Gradient Boosting	✘ No

2.4 Feature Engineering

Feature engineering adalah seni & sains **menciptakan features baru** dari raw data yang meningkatkan model performance.

2.4.1 Tipe-Tipe Feature Engineering

1. Polynomial Features

► Polynomial feature creation

2. Interaction Features

► Code

3. Domain-Specific Features

► Code


2.4.2 Feature Selection

Tidak semua features berguna. Feature selection menghilangkan features yang:

- Tidak relevant dengan target
- Redundant dengan features lain
- Meningkatkan noise/overfitting

Metode Feature Selection:

► Code



Feature Selection Methods

► Feature selection techniques

2.5 Data Validation & Quality Checks

Sebelum modeling, pastikan data berkualitas tinggi.

2.5.1 Data Leakage Prevention

Data Leakage Warning!

Data leakage terjadi ketika informasi dari test set “bocor” ke training set, menyebabkan overly optimistic model performance.

Contoh data leakage:

1. Scaling data sebelum train-test split
2. Using future information untuk predict past
3. Including target variable information di features
4. Tuning hyperparameters pada test set

Best Practices untuk mencegah data leakage:

► Data leakage prevention

2.5.2 Data Quality Checklist

```
# Comprehensive data quality checks
print("""
📋 DATA QUALITY CHECKLIST:

Completeness:
✓ No critical missing values (or properly handled)
✓ All rows have valid data

Accuracy:
✓ Values are within expected ranges
✓ No obvious data entry errors
✓ Outliers validated as legitimate

Consistency:
✓ Consistent data types
✓ Consistent naming conventions
✓ No duplicates (unless intentional)

Validity:
✓ All values conform to business rules
✓ Categorical variables have expected categories
✓ Numeric values are reasonable

Uniqueness:
✓ Primary key is unique
✓ No unintended duplicates
✓ De-duplication done properly
```

Timeliness:

- ✓ Data is current/recent enough
 - ✓ No time-series data gaps
 - ✓ Temporal consistency maintained
- """)

2.6 Complete Preprocessing Pipeline

Mari kita gabungkan semua langkah menjadi **preprocessing pipeline yang reusable**.

► Complete preprocessing pipeline

2.7 Case Study: Titanic Dataset Preprocessing

Mari aplikasikan semua konsep pada dataset Titanic.

Problem

Memprediksi apakah penumpang Titanic akan selamat (survival prediction)

Step-by-Step Preprocessing

► Complete Titanic preprocessing



Hands-on Exercise 2

Objektif: Practice EDA dan preprocessing dengan real dataset

Instruksi:

1. Load dataset (Titanic atau Iris)
2. Perform complete EDA:
 - Check shape, dtypes, missing values
 - Univariate analysis (histograms, box plots)
 - Bivariate analysis (correlations, scatter plots)
3. Preprocess data:

- Handle missing values
- Detect and handle outliers
- Encode categorical variables

4. Create feature engineering:

- At least 2 new features
- Perform feature selection

5. Build preprocessing pipeline

Bonus: Visualize before/after distributions

Review Questions

Conceptual Questions

1. Jelaskan perbedaan antara **Exploratory Data Analysis (EDA)** dan **Data Preprocessing**. Mengapa kedua tahap ini penting?
2. Anda menemukan bahwa 70% data dalam suatu column sudah missing. Apa keputusan yang tepat dan mengapa?
3. Jelaskan tiga metode untuk mendeteksi outliers. Bagaimana cara menentukan apakah outlier adalah error atau valid data?
4. Apa perbedaan antara **standardization (z-score)**, **normalization (min-max)**, dan **robust scaling**? Kapan menggunakan masing-masing?
5. Jelaskan **data leakage** dan berikan dua contoh konkret. Bagaimana cara mencegahnya?

Practical Questions

6. Dataset Anda memiliki kolom 'Age' dengan nilai ranging dari 0 hingga 1500 (error). Apa strategi pembersihan yang tepat?
7. Variabel 'Gender' memiliki 3 kategori: 'M', 'F', 'Unknown'. Bagaimana Anda akan mengenkodenya untuk ML model?
8. Anda punya feature 'Birth_Date'. Fitur apa yang bisa Anda engineer dari ini untuk prediksi churn?
9. Setelah preprocessing, Anda punya 150 features. Bagaimana cara memilih 20 features terbaik?

10. Di mana posisi scaling dalam preprocessing pipeline? Mengapa timing penting?



Key Takeaways

- ✓ EDA adalah langkah kritis untuk memahami data secara mendalam
- ✓ Missing values harus ditangani dengan strategi yang tepat, bukan hanya dihapus
- ✓ Outliers bisa valid atau error - validasi sebelum handling
- ✓ Encoding categorical variables adalah keharusan untuk ML algorithms
- ✓ Feature scaling penting untuk distance-based dan gradient-based algorithms
- ✓ Feature engineering dapat meningkatkan model performance significantly
- ✓ **Data leakage prevention** adalah fundamental untuk reliable models
- ✓ Preprocessing pipeline harus reproducible dan automated



References

Bacaan Lebih Lanjut

- Pandas Documentation: <https://pandas.pydata.org/>
- Scikit-learn Preprocessing: <https://scikit-learn.org/stable/modules/preprocessing.html>
- Feature Engineering Tutorial: <https://www.kaggle.com/learn/feature-engineering>

Tools & Libraries

- **Pandas:** Data manipulation and analysis
- **NumPy:** Numerical computing
- **Scikit-learn:** Preprocessing and feature engineering
- **Matplotlib/Seaborn:** Data visualization



Kesimpulan

Data preprocessing dan EDA adalah fondasi dari machine learning projects yang sukses. Waktu yang Anda investasikan dalam memahami dan membersihkan data akan membayar dividen besar dalam bentuk model performance yang lebih baik.

Di **Bab 3 (Classical ML Algorithms)**, kita akan menggunakan data yang sudah dipreproses ini untuk melatih berbagai algoritma dan memahami kekuatan serta kelemahan masing-masing. 🚀
